Mamba-Jev: Research Plan

Teste lineari in forma chiusa su backbone Mamba
per decisioni strutturate in un singolo forward pass

30 settembre 2026

1 Obiettivo e ipotesi

Mamba-Jev codifica l'intero prompt con un backbone Mamba e produce, in un solo forward pass, un output strutturato composto da tre elementi: una scelta tra C classi (*choice*), un punteggio di confidenza in $[0, 1]$ (*score*) e un flag di rejection per richieste fuori dominio (*noul*). L'elemento di innovazione è la sostituzione della discesa del gradiente sulle teste finali con una soluzione ai minimi quadrati in forma chiusa (*Exact QP Solver*).

Ipotesi da verificare.

H1 Teste in forma chiusa su feature congelate raggiungono una qualità entro una tolleranza δ (fissata *prima* degli esperimenti) da un linear probe addestrato con SGD.

H2 Il costo di fit delle teste si riduce sensibilmente: una passata sul dataset più una fattorizzazione $O(D^3)$ (entità da quantificare).

H3 L'eventuale perdita di calibrazione rispetto a una loss probabilistica (CE/BCE) è recuperabile con una calibrazione post-hoc leggera.

H4 A parità di taglia, l'inferenza single-pass ha latenza inferiore a un baseline autoregressivo che genera lo stesso output token per token.

2 Formulazione del solver

Sia $\boldsymbol{X} \in \mathbb{R}^{N \times D}$ la matrice delle feature (hidden state dell'ultimo token non-pad, dopo la norm finale) e $\boldsymbol{Y}_h$ il target della testa $h \in \{\text{choice}, \text{score}, \text{noul}\}$. Per ogni testa si risolve il problema ridge

$$\boldsymbol{W}_h^\star = \arg\min_{\boldsymbol{W}} \ \|\boldsymbol{X}\boldsymbol{W} - \boldsymbol{Y}_h\|_F^2 + \lambda \|\boldsymbol{W}\|_F^2 = (\boldsymbol{X}^\top \boldsymbol{X} + \lambda I)^{-1} \boldsymbol{X}^\top \boldsymbol{Y}_h, \qquad \lambda = \rho \, \frac{\operatorname{tr}(\boldsymbol{X}^\top \boldsymbol{X})}{D}. \quad (1)$$

La matrice di Gram e il termine noto si accumulano in streaming sui batch, $A = \sum_b \boldsymbol{X}_b^\top \boldsymbol{X}_b$ e $B_h = \sum_b \boldsymbol{X}_b^\top \boldsymbol{Y}_{h,b}$, con memoria $O(D^2)$ indipendente da N. Il costo è $O(ND^2)$ per l'accumulo e $O(D^3 + D^2 C)$ per la risoluzione (Cholesky in fp64). In ambiente multi-GPU le statistiche sono additive: una `all_reduce` restituisce la soluzione esatta sul dataset globale.

Poiché le teste sono lineari e la sigmoide è applicata dopo, i target sono espressi nello spazio dei logit:

Testa	Target $\boldsymbol{Y}_h$
choice	onehot(y); righe con label non definita escluse dal Gram
score	$\mathrm{logit}\big(\mathrm{clip}(s, \varepsilon, 1-\varepsilon)\big)$
noul	$\pm m$ (margine fissato)

Avvertenza. Questa è una regressione ai minimi quadrati sui target, *non* il minimizzatore di CE/BCE: è adatta ad argmax e ranking, meno alla calibrazione (vedi §5). Il caso non vincolato coincide con un QP senza vincoli, per cui esiste la soluzione chiusa; eventuali vincoli (per esempio output sul simplesso) richiederebbero un solver QP vero e proprio.

3 Protocollo sperimentale

Dati. Split train/validation/test. Per la testa *noul* il test include domini o classi *mai visti* in training. Validation usata per selezionare ρ e per la calibrazione. I dataset concreti sono ancora da definire. **Statistica:** almeno 3 seed, intervalli di confidenza bootstrap al 95%, confronti appaiati.

Configurazioni a confronto.

Id	Backbone	Teste	Loss teste	Ruolo
B1	SGD end-to-end	SGD	CE/BCE	riferimento superiore
B2	congelato	SGD (linear probe)	CE/BCE	isola l'effetto del solver
B3	congelato	forma chiusa	LS ridge	**metodo proposto**
B4	congelato	IRLS / L-BFGS	CE/BCE	ottimo per la loss corretta

Metriche.

Testa / aspetto	Metriche
choice	accuracy, macro-F1
score	Brier score, ECE
noul	AUROC, FPR@95%TPR
costo	tempo di fit (wall-clock), memoria di picco

4 Ablazioni sul solver

Fattore	Valori / domanda
Ridge ρ	scansione logaritmica (es. da 10^{-6} a 10^{-1}), scelta su validation
Mappatura target	margine m per noul, ε per score, scala one-hot per choice
Bias	colonna costante aggiunta a $\boldsymbol{X}$ contro assenza di bias; feature centrate
Pooling	ultimo token non-pad contro media dei token
Rapporto N/D	quanti campioni servono prima che la ridge smetta di dominare
Precisione	feature bf16 con accumulo fp32 contro accumulo fp64; TF32 on/off

5 Gap rispetto all'ottimo e calibrazione

Per quantificare cosa si perde usando LS al posto della loss corretta, si confronta B3 con la regressione logistica ridge sulle stesse feature. Per le teste binarie si usa Newton/IRLS, minimizzando $\mathcal{L}(\boldsymbol{w}) = -\sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)] + \frac{\lambda}{2}\|\boldsymbol{w}\|^2$ con

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} + \big(\boldsymbol{X}^\top S^{(t)} \boldsymbol{X} + \lambda I\big)^{-1} \big(\boldsymbol{X}^\top (\boldsymbol{y} - \boldsymbol{p}^{(t)}) - \lambda \boldsymbol{w}^{(t)}\big), \qquad S = \mathrm{diag}\big(p_i(1-p_i)\big), \tag{2}$$

mentre per choice (multiclasse) si usa L-BFGS. Domanda centrale: la calibrazione post-hoc (*temperature scaling* per choice e score, *Platt scaling* per noul, un pugno di parametri sulla validation) chiude il gap di ECE e Brier rispetto a B4? Si riporta l'ECE prima e dopo la calibrazione.

6 Varianti ibride

(i) **Alternanza.** Il backbone viene aggiornato con SGD per N step a teste fisse, poi le teste sono ricalcolate in forma chiusa. Le statistiche A, B_h vanno ricalcolate dopo ogni aggiornamento del backbone, perché le feature cambiano; in alternativa si usa una versione approssimata con fattore di oblio $A \leftarrow \gamma A + \boldsymbol{X}_b^\top \boldsymbol{X}_b$.

(ii) **Ridge differenziabile.** La soluzione $\boldsymbol{W}(\boldsymbol{X})$ è differenziabile (per esempio attraverso `cholesky_solve`) e permette una loss end-to-end sul batch. Se la dimensione del batch $B < D$ conviene la forma duale $\boldsymbol{W} = \boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{X}^\top + \lambda I)^{-1} \boldsymbol{Y}$, che richiede un sistema $B \times B$ invece di $D \times D$.

7 Benchmark di inferenza

Si confrontano Mamba-Jev (un forward, teste lineari con costo $O(D(C+2))$) e un baseline autoregressivo della stessa taglia che genera l'output strutturato token per token. Variabili: lunghezza del prompt L, batch size, lunghezza dell'output generato; hardware e dtype fissi. Metriche: latenza p50/p95 per richiesta, throughput, memoria, oltre alla qualità dell'output a parità di task.

Precisazione sul claim O(1). Il costo è costante *nel numero di token generati*; la codifica del prompt resta lineare in L (scan del backbone SSM, non quadratica come l'attenzione). Il paper dovrebbe formulare il claim in questi termini.

8 Rischi e mitigazioni

Rischio	**Effetto**	**Mitigazione**
Classi sbilanciate	LS sotto-pesa le classi rare	LS pesata per riga; ricalibrazione delle soglie
Assenza di bias	offset dei target non rappresentabile	colonna costante in $\boldsymbol{X}$; feature centrate
$N < D$ o collinearità	sistema mal condizionato	ridge, soluzione in fp64, monitoraggio di cond(A)
Drift delle feature	pesi obsoleti dopo un update del backbone	re-solve dopo ogni aggiornamento
Precisione bf16	Gram rumorosa	accumulo fp32, TF32 disattivato
Left-padding	lo stato ricorrente include i pad	right-padding, test di regressione
Claim O(1)	ambiguità nel paper	formulazione rispetto ai token in output

9 Fasi e deliverable

Fase	**Contenuto**	**Deliverable**
F0	Infrastruttura, pipeline dati, verifica del solver contro `lstsq`	repo funzionante, self-test verde
F1	Baseline B1–B3	tabella comparativa con IC
F2	Ablazioni, B4, calibrazione	analisi del gap LS contro CE/BCE
F3	Varianti ibride (i)–(ii)	confronto con B3
F4	Benchmark di inferenza e stesura	risultati di latenza, bozza del paper

Criteri di successo (da fissare prima di F1). (1) B3 entro δ da B2 su accuracy di choice e AUROC di noul; (2) ECE di B3 dopo calibrazione comparabile a B4; (3) speed-up di fit misurato e riportato con IC; (4) riduzione di latenza rispetto al baseline autoregressivo confermata su più valori di L.